Universidad Autónoma Chapingo

Departamento de Mecánica Agrícola

Ingeniería Mecatrónica Agrícola

Informe de prácticas

Asignatura:

Inteligencia Artificial

Nombre del profesor:

Luis Arturo Soriano Avendaño

Alumno:

Cocotle Lara Jym Emmanuel
[1710451-3]

GRADO:	GRUPO:
7°	7

Chapingo, Texcoco Edo. México

Fecha de entrega: 17/12/2021

Índice

Introducción

A través del tiempo la inteligencia artificial ha ido evolucionando de manera progresiva y con ello sus aplicaciones en diferentes campos, ya que en el seno de la inteligencia artificial como ciencia y tecnología se han ido acumulando conocimientos sobre cómo emular las diversas capacidades del ser humano para exhibir comportamientos inteligentes y se han desarrollado sistemas cada vez más perfeccionados que reproducen parcialmente dichas capacidades (Díez, R. P., Gómez, A. G., & de Abajo Martínez, N. 2001).

La enciclopedia de la inteligencia artificial la define como un campo de la ciencia y la ingeniería que se ocupa de la comprensión, desde el punto de vista informático, de lo que se denomina comúnmente comportamiento inteligente. También se ocupa de la creación de artefactos que exhiben este comportamiento.

La inteligencia artificial se basa en el análisis de cómo los seres humanos resuelven o buscan soluciones a cada uno de los innumerables problemas con los que se encuentran continuamente.

Los sistemas desarrollados con técnicas de inteligencia artificial deben enfrentarse con problemas para los que no se conoce la secuencia exacta de acciones que deben realizarse para encontrar su solución este tipo de estrategias de resolución de problemas se conocen como algoritmos de búsqueda.

A través de las prácticas de este informe se busca comprender los conceptos de la inteligencia artificial con ayuda de la programación en Python, con el objetivo de reforzar el conocimiento teórico que se mostró en las clases.

Desarrollo

Práctica 1: Red Neuronal Perceptrón

Objetivo

Entrenamiento de una red neuronal perceptrón para la obtención de una matriz de pesos sinápticos y un vector de polarización además del error con el fin de poder reconocer dígitos en un display de 7 segmentos.

Programa

```
# Universidad Autónoma Chapingo
# Departamento de Ingeniería Mecánica Agrícola
# Ingeniería Mecatrónica Agrícola
# Jym Emmanuel Cocotle Lara
```

```python
# 7° 7

#Librería para manejo de vectores y arreglos
import numpy as np

# Función escalón
def hardlim(n):
        if n > 0:
                value = 1
        else:
                value = 0

        return value

# Entradas
# a,b,c,d,e,f,g
P = [[1,1,1,1,1,1,0], # 0
     [0,1,1,0,0,0,0],  # 1
     [1,1,0,1,1,0,1],  # 2
     [1,1,1,1,0,0,1],  # 3
     [0,1,1,0,0,1,1],  # 4
     [1,0,1,1,0,1,1],  # 5
     [1,0,1,1,1,1,1],  # 6
     [1,1,1,0,0,0,0],  # 7
     [1,1,1,1,1,1,1],  # 8
     [1,1,1,1,0,1,1]]  # 9


# Valores esperados
t_pares = [1,0,1,0,1,0,1,0,1,0]
t_mayores_5 = [0,0,0,0,0,0,1,1,1,1]
t_numeros_p = [0,0,1,1,0,1,0,1,0,0]
t_impares = [0,1,0,1,0,1,0,1,0,1]

t = t_pares


# Error
e = np.ones(10)

# Matriz de pesos sinápticos
W = 2*np.random.rand(1,7)-1
# Vector de polarización
b = 2*np.random.rand(1)-1

# Establecemos un for que reccorra el número de épocas
for epocas in range(500):
   # Establecemos un for que reccorra el número de patrones de prueba
        for q in range(10):
                a = hardlim(np.dot(W,P[q])+b) # Salida de la neurona
perceptrón
                e[q] = t[q]-a # Error
                W += np.dot(e[q],P[q]).T # Transpuesta
                b += e[q]

# Resultados
print(f"W: {W}")
```

```
print(f"b: {b}")
print(f"e: {e}")
```

Resultados

```
In [17]: runfile('D:/Documents/Chapingo/7° semestre/
Inteligencia Artificial/praccc/P1.py', wdir='D:/Documents/
Chapingo/7° semestre/Inteligencia Artificial/praccc')
W: [[-0.41395686  0.22983101 -1.87298064 -1.20732072
6.74445788  1.65335086
  -0.26540289]]
b: [0.73234912]
e: [0. 0. 0. 0. 0. 0. 0. 0. 0. 0.]
```

Ilustración 1.- Resultados del entrenamiento de la red neuronal perceptrón.

Después del entrenamiento con 500 épocas se pudo obtener la matriz de pesos sinápticos el vector de polarización y el error siendo este último una matriz de ceros siendo esta matriz el error deseado.

Práctica 2: Red Perceptrón

Objetivo

Diseño de una red neuronal perceptrón para la clasificación de libros.

Programa

```
# Universidad Autónoma Chapingo
# Departamento de Ingeniería Mecánica Agrícola
# Ingeniería Mecatrónica Agrícola
# Jym Emmanuel Cocotle Lara
# 7° 7

# Librerías
# Para vectores y matrices
import numpy as np
# Para graficación
import matplotlib.pyplot as plt

# Función de activación
def hardlim(n):
        if n[0][0] > 0:
                value1 = 1
        else:
                value1 = 0

        if n[1][0] > 0:
                value2 = 1
        else:
                value2 = 0

        return [[value1],[value2]]


# Arreglo de entradas
P = np.array([[0.7,1.5,2.0,0.9,4.2,2.2,3.6,4.5], # peso
                        [3,5,9,11,0,1,7,6]]) #frecuencia

# Valores esperados
t = np.array([[0,0,0,0,1,1,1,1],
```

```
                        [0,0,1,1,0,0,1,1]])

# error
e = np.array(np.ones((2,8)))

# inicializamos de forma aleatoria
W = 2*np.random.rand(2,2)-1 # matriz de pesos sinápticos
b = 2*np.random.rand(2,1)-1 # vector de polarizaciÃ³n

for epocas in range(40): # número de épocas
        for q in range(8): # número de patrones de prueba
                a = hardlim(np.dot(W,P[:,q].reshape(-1,1))+b) #
convierte a vector de 1 columna
                e[:,q] = (t[:,q].reshape(-1,1)-a).T # error
                W += np.dot(e[:,q].reshape(-1,1),P[:,q].reshape(-
1,1).T)
                b += e[:,q].reshape(-1,1)

# Graficación del resultado
fig,ax = plt.subplots()

# Ligeros y poco usados
ax.scatter(P[0][0],P[1][0],marker='^')
ax.scatter(P[0][1],P[1][1],marker='^')

# Ligeros y muy usados
ax.scatter(P[0][2],P[1][2],marker='s')
ax.scatter(P[0][3],P[1][3],marker='s')

# Pesados y poco usados
ax.scatter(P[0][4],P[1][4],marker='o')
ax.scatter(P[0][5],P[1][5],marker='o')

# Pesados y muy usados
ax.scatter(P[0][6],P[1][6],marker='*')
ax.scatter(P[0][7],P[1][7],marker='*')


points = np.arange(0,6,0.01)

# Primera neurona
ax.plot(points, (-b[0][0]/W[0,1])-(W[0,0]/W[0,1])*points)
ax.plot(points, (-b[1][0]/W[1,1])-(W[1,0]/W[1,1])*points)
plt.show()
```

Resultados

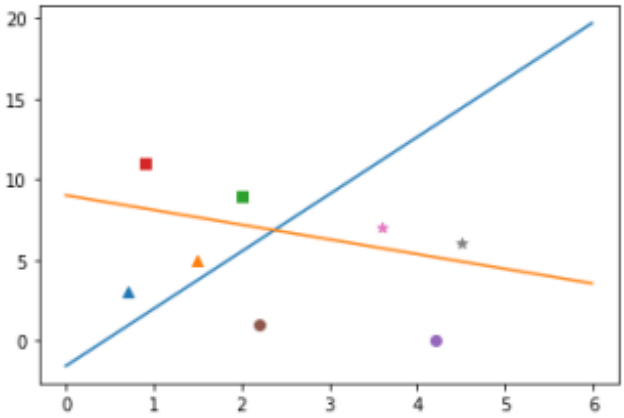

Ilustración 2.- Resultados de la clasificación de libros por medio de una red neuronal perceptrón

Como podemos observar en la figura dos la red neuronal puede clasificar los libros de manera adecuada, sin embargo, puede llegar a tener algunos errores al momento de la clasificación ya que las fronteras de decisión están muy cerca de los datos.

Práctica 3: Red Adaline-Widrow Hoff

Objetivo

Diseño de una red neuronal Adaline para la clasificación de libros de acuerdo con su peso y a su uso.

Programa

```
# Universidad Autónoma Chapingo
# Departamento de Ingeniería Mecánica Agrícola
# Ingeniería Mecatrónica Agrícola
# Jym Emmanuel Cocotle Lara
# 7° 7

# Librerías
# Para vectores y matrices
import numpy as np
# Para graficación
import matplotlib.pyplot as plt

# Función hardlim
def hardlim(n):
        if n[0][0] > 0:
                value1 = 1
        else:
                value1 = -1
        if n[1][0] > 0:
                value2 = 1
        else:
                value2 = -1
        return [[value1],[value2]]

# Entradas
P = np.array([[0.7,1.5,2.0,0.9,4.2,2.2,3.6,4.5],
                        [3,5,9,11,0,1,7,6]])

# Vector aumentado
```

```
Z = np.vstack([P,[1,1,1,1,1,1,1,1]])

# Valores esperados : cambia 0 a -1
T = np.array([[-1,-1,-1,-1,1,1,1,1],
                          [-1,-1,1,1,-1,-1,1,1]])

# Algotimo de Widrow-Hoff
R = np.dot(Z,Z.T)/8 # Q=8
H = np.dot(Z,T.T)/8
X = np.linalg.inv(R) @ H
W = X[:2,:2].T
b = X[2:].reshape(-1,1)

# Verificar la solución con el algoritmo perceptrón
e = np.array(np.ones((2,8)))

for q in range(8):
    # Conversión del vector a un vector de 1 columna
        a = hardlim(np.dot(W,P[:,q].reshape(-1,1))+b)
        e[:,q] = (T[:,q].reshape(-1,1)-a).T

print(e)

# Graficación
fig,ax = plt.subplots()

# Ligeros y poco usados
ax.scatter(P[0][0],P[1][0],marker='^')
ax.scatter(P[0][1],P[1][1],marker='^')

#Ligeros y muy usados
ax.scatter(P[0][2],P[1][2],marker='s')
ax.scatter(P[0][3],P[1][3],marker='s')

#Pesados y poco usados
ax.scatter(P[0][4],P[1][4],marker='o')
ax.scatter(P[0][5],P[1][5],marker='o')

#Pesados y muy usados
ax.scatter(P[0][6],P[1][6],marker='*')
ax.scatter(P[0][7],P[1][7],marker='*')

points = np.arange(0,6,0.01)

# Primera neurona
ax.plot(points, (-b[0][0]/W[0,1])-(W[0,0]/W[0,1])*points)
ax.plot(points, (-b[1][0]/W[1,1])-(W[1,0]/W[1,1])*points)
ax.set_xlim([0,6])
ax.set_ylim([-2,14])
plt.show()
```

Resultados

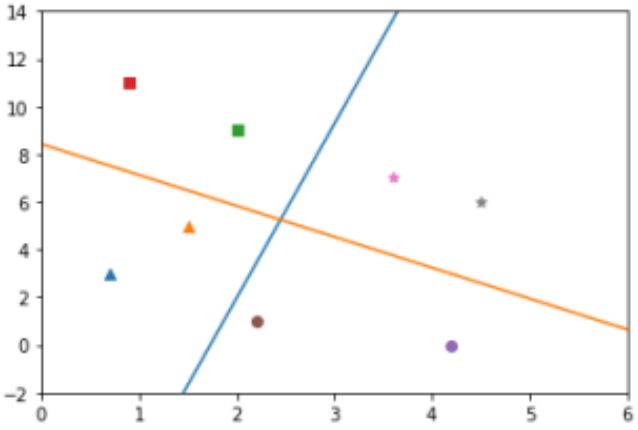

Ilustración 3.- Resultado de la clasificación de libros.

Como podemos observar la clasificación en este programa fue más acertada ya que las fronteras de decisión son más claras y por lo tanto la clasificación es más acertada.

Práctica 4: Red Adaline: Reconocimiento de números

Objetivo

Entrenamiento de una red Adaline para reconocimiento de números en un display de 7 segmentos.

Programa

```
# Universidad Autónoma Chapingo
# Departamento de Ingeniería Mecánica Agrícola
# Ingeniería Mecatrónica Agrícola
# Jym Emmanuel Cocotle Lara
# 7° 7

# Librerías
# Para vectores y matrices
import numpy as np
# Para graficación
import matplotlib.pyplot as plt

# Función hardlim
def hardlim(n):
        if n[0][0] > 0:
                value1 = 1
        else:
                value1 = -1
        if n[1][0] > 0:
                value2 = 1
        else:
                value2 = -1
        if n[2][0] > 0:
                value3 = 1
        else:
                value3 = -1
        return [[value1],[value2],[value3]]


# a,b,c,d,e,f,g
```

```
P = np.array([[1,1,1,1,1,1,0],  #0
                    [0,1,1,0,0,0,0],  #1
                    [1,1,0,1,1,0,1],  #2
                    [1,1,1,1,0,0,1],  #3
                    [0,1,1,0,0,1,1],  #4
                    [1,0,1,1,0,1,1],  #5
                    [1,0,1,1,1,1,1],  #6
                    [1,1,1,0,0,0,0],  #7
                    [1,1,1,1,1,1,1],  #8
                    [1,1,1,1,0,1,1]]) #9

# Transpuesta de P
P = P.transpose()

# Vector aumentado
Z = np.vstack([P,np.ones(10)])


# Valores esperados
t_pares = [1, -1, 1, -1, 1, -1, 1, -1, 1, -1]
t_mayores_5 = [-1,-1,-1,-1,-1,-1,1,1,1,1]
t_numeros_p = [-1,-1,1,1,-1,1,-1,1,-1,-1]
t_impares = [-1,1,-1,1,-1,1,-1,1,-1,1]

# Valores esperados
T = np.array([t_pares,t_mayores_5,t_numeros_p])

# Algoritmo Adaline
# 10 = número de valores esperados
R = np.dot(Z,Z.T)/10
H = np.dot(Z,T.T)/10
X = np.linalg.inv(R) @ H
W = X[:7,:3].T
b = X[7,:3].reshape(-1,1)

print(f"W: {W}")
print(f"b: {b}")

# Verificando la solución
e = np.ones((3,10))


for q in range(10):
        a = hardlim(np.dot(W,P[:,q].reshape(-1,1))+b)
        e[:,q] = (T[:,q].reshape(-1,1)-a).T

print(f"Error: {e}")
```

Resultados

```
Inteligencia Artificial/praccc/P4.py', wdir='D:/Documents/
Chapingo/7° semestre/Inteligencia Artificial/praccc')
W: [[-0.33333333  0.33333333 -0.33333333 -1.          2.
0.66666667
   0.66666667]
 [ 2.66666667  0.33333333  1.66666667 -2.5         1.
0.16666667
   1.16666667]
 [ 1.66666667 -0.66666667 -1.33333333 -0.5        -1.
-0.83333333
   0.16666667]]
b: [[-0.66666667]
 [-3.66666667]
 [ 1.33333333]]
Error: [[0. 0. 0. 0. 0. 0. 0. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 2.]
 [0. 0. 0. 0. 0. 0. 0. 0. 0.]]
```

Ilustración 4.- Resultados del entrenamiento de la práctica 4.

Como podemos observar el entrenamiento logré adquirir la matriz de pesos sinápticos y el vector de polarización para que de esta forma se puedan reconocer los números de manera adecuada, sin embargo, el entrenamiento no fue del todo satisfactorio ya que en la matriz de error se encuentra un valor no deseado por lo que probablemente al momento de emplear los valores de la matriz de pesos sinápticos y el vector de polarización este pueda no identificar adecuadamente los números.

Práctica 5: Red Adaline: Clasificación de números manuscritos.

Objetivo

Entrenamiento de una red neuronal Adaline para el reconocimiento de números manuscritos.

Programa

```
# Universidad Autónoma Chapingo
# Departamento de Ingeniería Mecánica Agrícola
# Ingeniería Mecatrónica Agrícola
# Jym Emmanuel Cocotle Lara
# 7° 7


# Librerías
# Para vectores y matrices
import numpy as np
# Para graficación
import matplotlib.pyplot as plt

# Ruta del archivo
data_path = "Data/NumerosManuscritos.csv"
# Establecemos a P con los datos del archivo
P = np.loadtxt(data_path,delimiter=",")
# Convertimos el archivo en un arreglo
P = np.array(P)

Z = np.vstack([P,np.ones((1,5000))])

# Valores esperados
T = np.vstack([np.ones((1,500)),-np.ones((9,500))]) # Agregar filas
for i in range(1,10):
```

```
        T = np.hstack([T,np.vstack([-
np.ones((i,500)),np.ones((1,500)),-np.ones((9-i,500))])]) # agregar
columnas

# Red neuronal Adaline
# 5000 = número de datos
R = np.dot(Z,Z.T)/5000
# 5000 = número de datos
H = np.dot(Z,T.T)/5000
# Multiplicación de matrices pseudoinversa
X = np.linalg.pinv(R) @ H

# Matriz de pesos sinápticos
W = X[0:400,:].T
# Vector de polarización
b = X[400,:].reshape(-1,1)

# Visualizar qué tan bien lo hizo
index = np.ones((1,5000))
neurona_sal = np.ones((1,5000))

for q in range(5000):
        a = np.dot(W,P[:,q]).reshape(-1,1)+b
   # Función de activación
        neurona_sal[:,q] = np.amax(a)
        posicion = np.where(a==neurona_sal[:,q])
        index[:,q] = posicion[0]

y = np.zeros((1,500))
for j in range(1,10):
        y = np.hstack([y,j*np.ones((1,500))])

numeros_aciertos = np.sum(y==index)
porcentaje_aciertos = (numeros_aciertos/5000)*100
print(f"{porcentaje_aciertos} % de aciertos")

for k in range(10):
        indice = np.round((4999*np.random.rand(1)+1),0)
        numero_reconocido = index[:,int(indice)]
        print(f"Número reconocido: {numero_reconocido}")

        pixels = P[:,int(indice)].reshape(20,20).T
        plt.imshow(pixels, cmap="gray")
        plt.title("Número reconocido: "+str(int(numero_reconocido)))
        plt.show()
```

Resultados

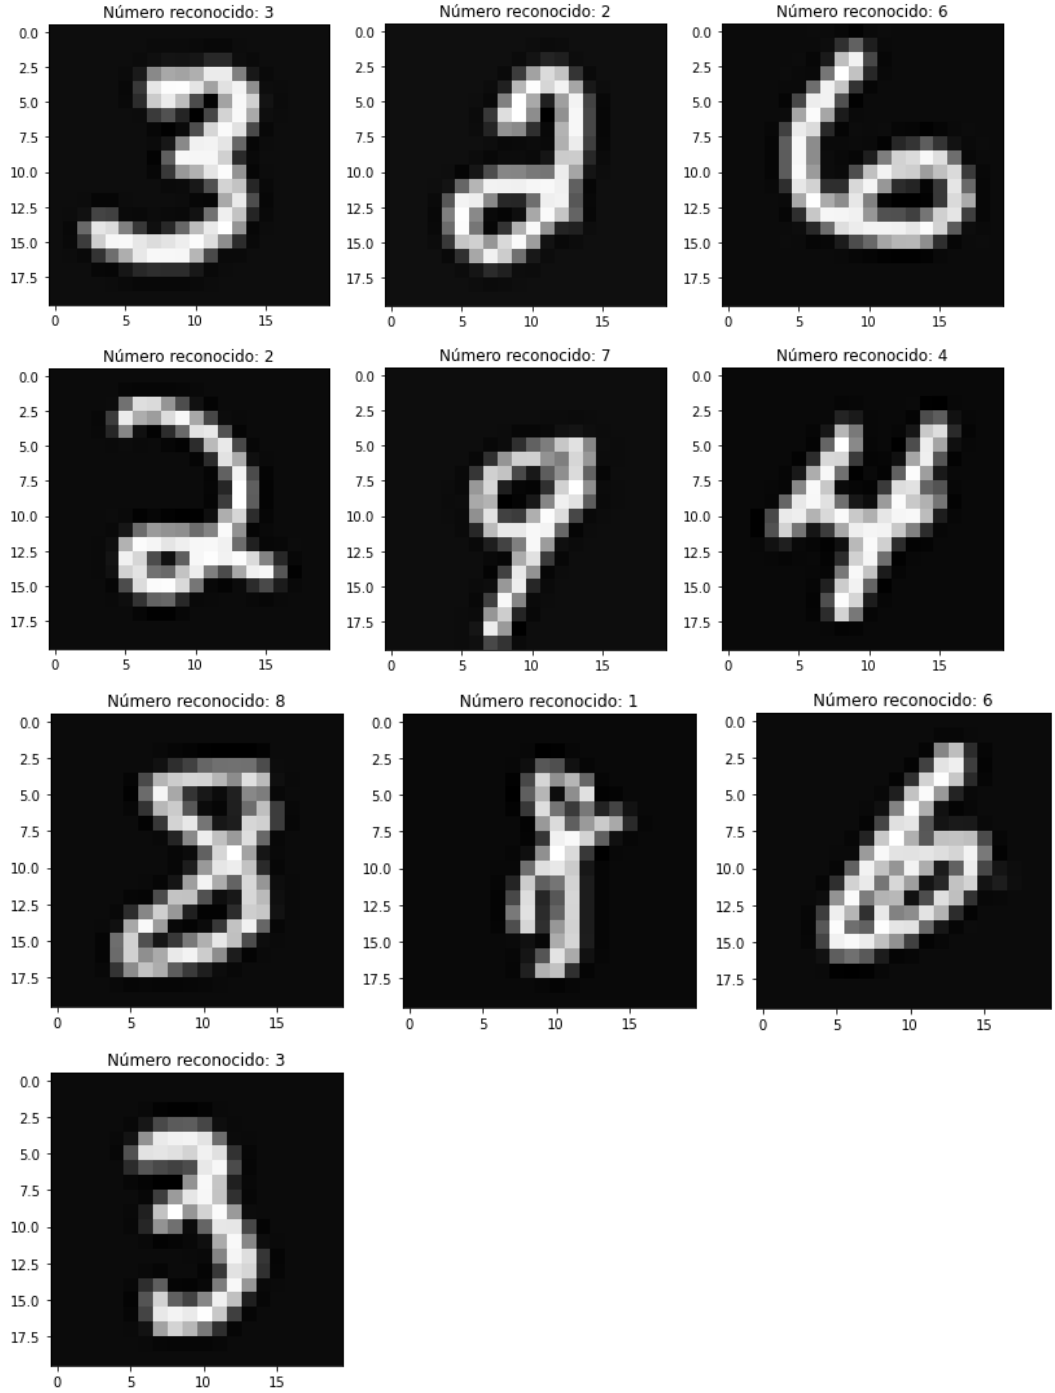

Como podemos observar después del entrenamiento el programa ejecutó algunos ejemplos para reconocimiento de números y como se puede apreciar en las imágenes este reconocimiento no fue del todo fiable, sin embargo, tiene cierto grado de asertividad.

Práctica 6: Red Neuronal Multicapa

Objetivo

Entrenamiento de una red neuronal multicapa para realizar la función XOR

Programa

```
# Universidad Autónoma Chapingo
# Departamento de Ingeniería Mecánica Agrícola
```

```
# Ingeniería Mecatrónica Agrícola
# Jym Emmanuel Cocotle Lara
# 7° 7

# Librerías
# Para vectores y matrices
import numpy as np
# Para graficación
import matplotlib.pyplot as plt

# Función tangente sigmoidal
class TanSig:
        def __call__(self, x):
                return np.tanh(x)

        def deriv(self,x,y):
                return 1.0 - np.square(y)

# tangente hiperbólica
def tanh(x):
        t = (np.exp(x) - np.exp(-x))/(np.exp(x)+np.exp(-x))
        return t


# Entradas
P = np.array([[0,0,1,1],
                              [0,1,0,1]])

# Valores esperados
T = np.array([-1,1,1,-1]) # cambiamos 0 por -1
# Número de entrada de datos
Q = 4
# Número de neuronas
n1 = 34
# Epsilon: rango de valores iniciales
ep = 1 # parámetro que afectará a W y b iniciales

# Matriz de pesos sinápticos 1
W1 = ep*2*np.random.rand(n1,2)-1
# Vector de polarización 1
b1 = ep*2*np.random.rand(n1,1)-1

# Matriz de pesos sinápticos 2
W2 = ep*2*np.random.rand(1,n1)-1
# Vector de polarización 2
b2 = ep*2*np.random.rand(1,1)-1

total_epocas = 11000
a2 = np.array(np.zeros((1,Q)))
error_cuadratico_medio = np.array(np.zeros((1,total_epocas)))
alpha = 0.001

for epocas in range(total_epocas):
        sum_error = 0
        for q in range(Q):
                # Progagación de la entrada a la salida
                a1 = tanh(np.dot(W1,P[:,q].reshape(-1,1))+b1)
```

```
                a2[:,q] = tanh(np.dot(W2,a1)+b2)

                # Retropropagación de la sensibilidad
                e = T[q]-a2[:,q]

                # Sensibilidad 2
                s2 = -2*(1-(a2[:,q]**2))*e

                # Sensibilidad 1
                s1 = (np.diag(1-(a1**2))*W2.T)*s2

                # Actualización de pesos sinapticos (W) y vectores de
polarización (b)
                W2 = W2 - alpha*s2*a1.T
                b2 = b2 - alpha*s2
                W1 = W1 - alpha*s1*P[:,q].reshape(-1,1).T
                b1 = b1 - alpha*s1

                # error cuadrático medio
                sum_error = e**2 + sum_error

        error_cuadratico_medio[:,epocas] = sum_error/Q

# Error cuadrático medio
print(f"EQM: {error_cuadratico_medio}")

a_verificacion = np.array(np.zeros((1,Q)))

# Verificamos el resultado
for q in range(Q):
        a_verificacion[:,q] =
tanh(np.dot(W2,tanh(np.dot(W1,P[:,q].reshape(-1,1))+b1))+b2)

print(f"Valores esperados: {T}")
print(f"Valores de NN: {a_verificacion}")

# Frontera de decisión
# Gráfica de contorno
u = np.linspace(-2,2,100)
v = np.linspace(-2,2,100)
z = np.array(np.zeros((100,100)))

for i in range(100):
        for j in range(100):
                z[i,j] =
tanh(np.dot(W2,(tanh(np.dot(W1,[[u[i]],[v[j]]])+b1)))+b2)

x = np.arange(0,total_epocas,1)

fig,(ax1,ax2) = plt.subplots(1,2)

ax1.set_title('Error cuadrático medio')
ax1.plot(x,error_cuadratico_medio.reshape(-1,1))
ax1.set(xlabel='#épocas',ylabel='Error')

ax2.set_title('Compuerta lógica XOR')
ax2.contour(u, v, z.T, 5, linewidths = np.arange(-0.9, 0, 0.9))
```

```
ax2.scatter(P[0][0],P[1][0], marker='o')
ax2.scatter(P[0][1],P[1][1], marker='o')
ax2.scatter(P[0][2],P[1][2], marker='o')
ax2.scatter(P[0][3],P[1][3], marker='o')

# Límites de los ejes
ax2.set_xlim([-0.5,1.5])
ax2.set_ylim([-0.5,1.5])

plt.show()
```

Resultados

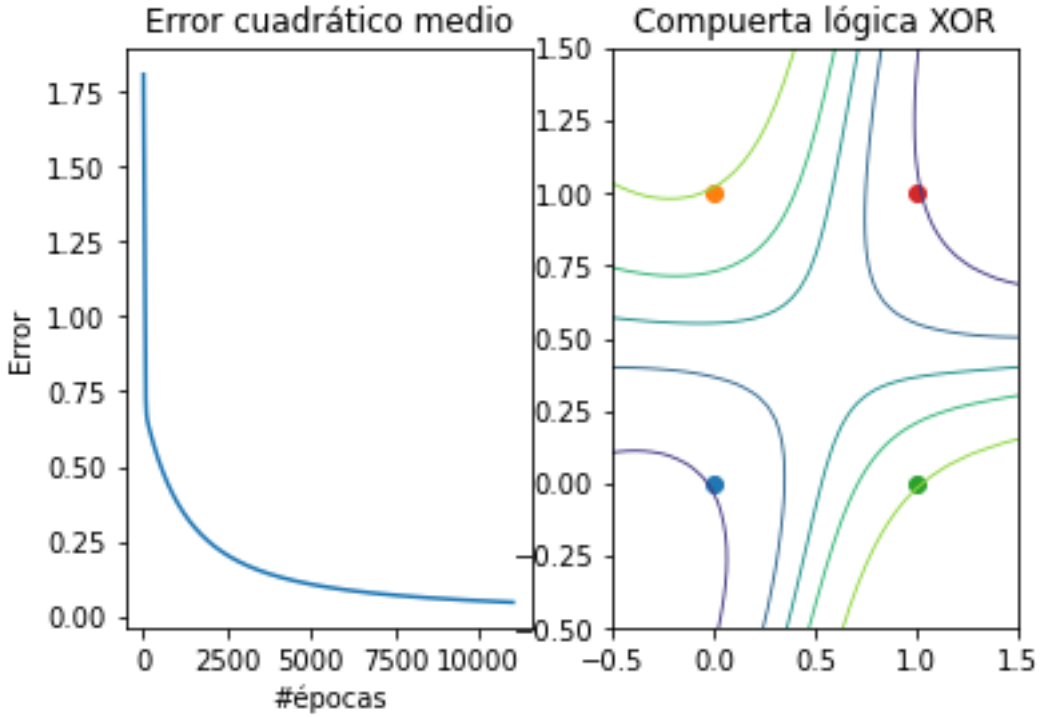

Ilustración 5.- Resultados gráficos de la separabilidad de datos.

Como podemos observar para esta práctica es necesario realizar una separabilidad no lineal, para poder realizar la separación de datos de manera adecuada

```
In [7]: runfile('D:/Documents/Chapingo/7° semestre/
Inteligencia Artificial/praccc/P6.py', wdir='D:/Documents/
Chapingo/7° semestre/Inteligencia Artificial/praccc')
EQM: [[1.80712198 1.78964641 1.77149206 ... 0.04748749
0.04748298 0.04747848]]
Valores esperados: [-1  1  1 -1]
Valores de NN: [[-0.78499323  0.78327103  0.78396889
-0.78342182]]
```

Ilustración 6.- Valores de la red neuronal

En la ilustración 6 se muestran los valores del error cuadrático medio los valores esperados y los valores de la red neuronal.

Práctica 7: Descenso por gradiente estocástico

Objetivo

Realizar el entrenamiento de un algoritmo de descenso estocástico por gradiente para la clasificación de los patrones de 100 números.

Programa

```
# Universidad Autónoma Chapingo
# Departamento de Ingeniería Mecánica Agrícola
# Ingeniería Mecatrónica Agrícola
# Jym Emmanuel Cocotle Lara
# 7° 7

# Librerías
# Para vectores y matrices
import numpy as np
# Para graficación
import matplotlib.pyplot as plt

# Función de activación tangente sigmoidal
def tanh(x):
        value = (np.exp(x)-np.exp(-x))/(np.exp(x)+np.exp(-x))
        return value

# Ruta del archivo
data_path = ("Data/Clasificacion100.csv")
P = np.loadtxt(data_path,delimiter=",")
P = np.array(P) # (2 filas, 200 columnas)
Q = 200

# Valores esperados
T = np.ones((1,200))
T[:,100:] = -1

# Valores iniciales
n = 20 # Número de neuronas
ep = 1 # Factor de escalamiento

# Parámetros
# Matrices de pesos sinapticos y vectores de polarización
W1 = ep*2*np.random.rand(n,2)-ep
b1 = ep*2*np.random.rand(n,1)-ep

W2 = ep*2*np.random.rand(1,n)-ep
b2 = ep*2*np.random.rand(1,1)-ep


alfa = 0.01
numero_epocas = 500
error_qua_medio = np.array(np.zeros((1,numero_epocas)))
a2 = np.array(np.zeros((1,Q)))



for epocas in range(numero_epocas):
        sum_error = 0
        for q in range(Q):
```

```
                q = np.random.randint(0,200)

                # Propagación hacia delante (desde la entrada hasta la
salida)
                a1 = tanh(np.dot(W1,P[:,q].reshape(-1,1))+b1)
                a2[:,q] = tanh(np.dot(W2,a1)+b2)

                # Cálculo de la sensibilidad
                e = T[:,q]-a2[:,q]
                s2 = -2*(1-a2[:,q]**2)*e
                s1 = (np.diag(1-a1**2)*W2.T)*s2

                # Actualizando los pesos sinapticos
                W2 = W2 -alfa*s2*a1.T
                b2 = b2 -alfa*s2

                W1 = W1 -alfa*s1*P[:,q].reshape(-1,1).T
                b1 = b1 -alfa*s1

                sum_error = e**2+sum_error
        error_qua_medio[:,epocas] = sum_error/Q

print(f"Error cuadrático medio: {error_qua_medio}")

# Visualizamos el error cuadrático medio
x = np.arange(0,numero_epocas,1)
fig, ax = plt.subplots()
ax.set_title("Error cuadrático medio")
ax.plot(x,error_qua_medio.reshape(-1,1))
ax.set(xlabel="# Epocas",ylabel = "MSE")

# Verificamos el algoritmo de backpropagation
a_verificacion = np.array(np.zeros((1,Q)))
for q in range(Q):
        a_verificacion[:,q] =
tanh(np.dot(W2,tanh(np.dot(W1,P[:,q].reshape(-1,1))+b1))+b2)

x2 = np.arange(0,200,1)
fig2,ax2 = plt.subplots()
ax2.scatter(x2[100:],a_verificacion[:,100:].reshape(-1,1),color='red')
ax2.scatter(x2[:100],a_verificacion[:,:100].reshape(-
1,1),color='blue')

# Gráficas de contorno
u = np.linspace(-15,15,50)
v = np.linspace(-15,15,50)
z = np.array(np.zeros((50,50)))

for i in range(50):
        for j in range(50):
                z[i,j] =
tanh(np.dot(W2,tanh(np.dot(W1,[[u[i]],[v[j]]])+b1))+b2)

fig3,ax3 = plt.subplots()
ax3.scatter(P[0][100:],P[1][100:],marker="x",color='red')
ax3.scatter(P[0][:100],P[1][:100],marker="*",color='blue')
ax3.contour(u,v,z.T,linewidths=np.arange(-0.9,0,0.9))
```

```
plt.show()
```

Resultados

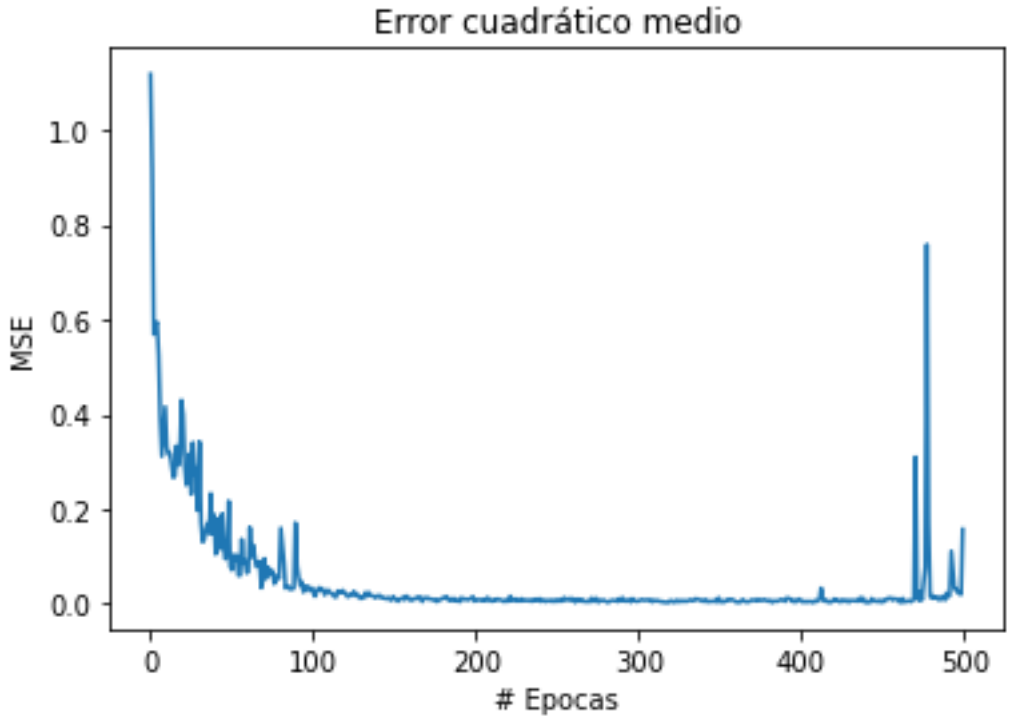

Ilustración 7.- Valor del error cuadrático medio a través de las épocas.

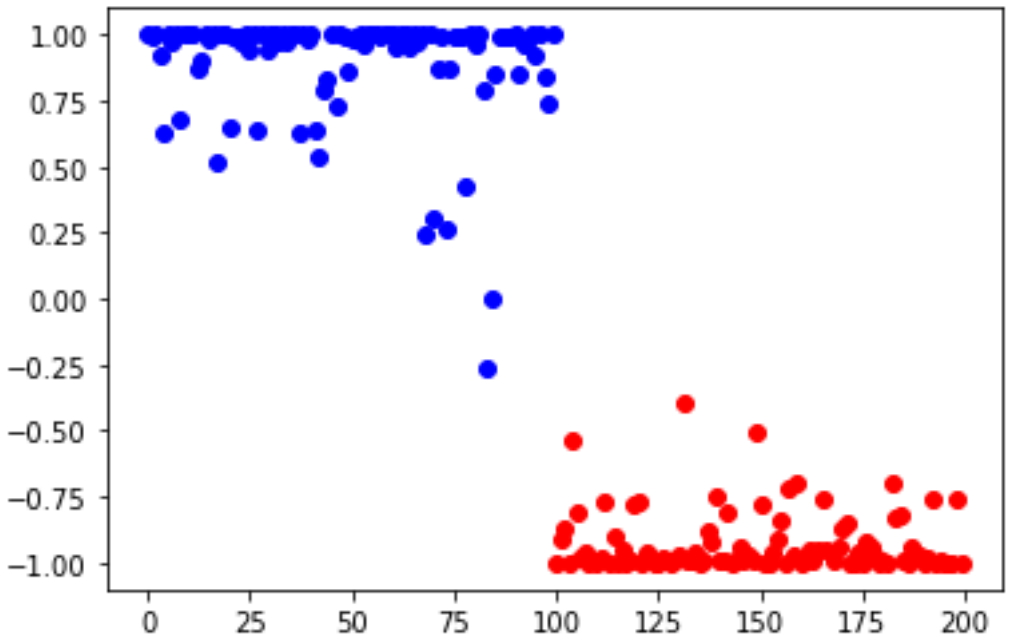

Ilustración 8.- Clasificación de los números.

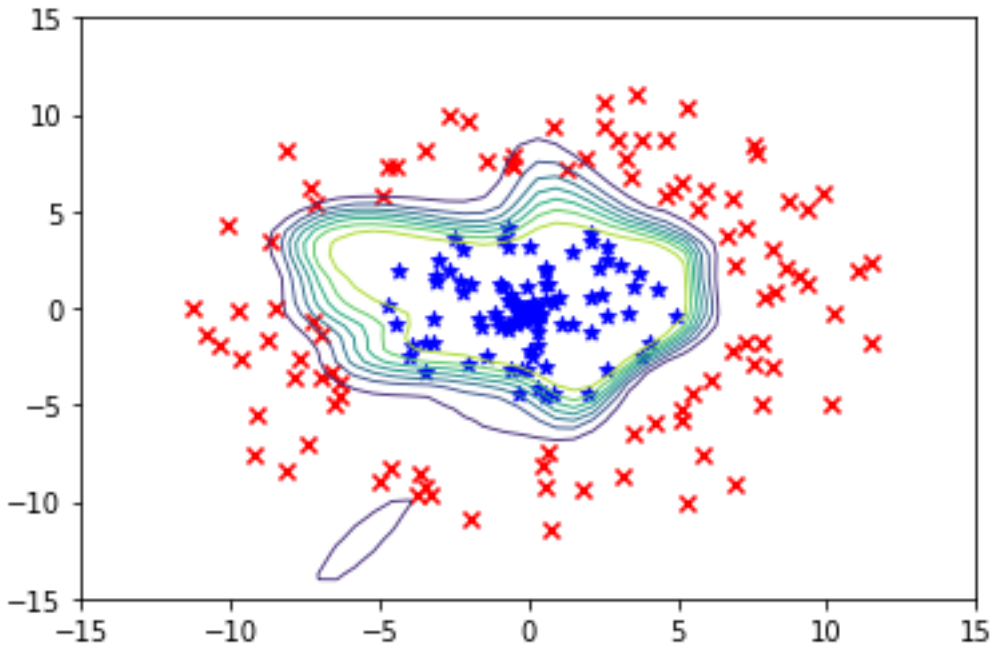

Ilustración 9.- Grafica de contornos con base en los números.

La clasificación de los números se puede observar claramente en la ilustración número 9, sin embargo, la eficacia de la clasificación puede mejorar.

Práctica 8: Red Neuronal de Propagación hacia atrás

Objetivo

Entrenamiento de una red neuronal multicapa para la aproximación de un modelo de regresión para los precios de una acción.

Programa

```
# Universidad Autónoma Chapingo
# Departamento de Ingeniería Mecánica Agrícola
# Ingeniería Mecatrónica Agrícola
# Jym Emmanuel Cocotle Lara
# 7° 7

# Librerías
# Para vectores y matrices
import numpy as np
# Para graficación
import matplotlib.pyplot as plt

# Función de activación sigmoidal
def sigmod(x):
    value = 1/(1+np.exp(-x))
    return value

# Ruta del archivo
data_path = ("data/RegresionBursatil.csv")
Data = np.loadtxt(data_path,delimiter=",")
Data = np.array(Data) # datos de entrada, datos deseados

P = Data[0]
T = Data[1]
```

```
Q = 31

# Número de neuronas de la primera capa
n1 = 30
# Número de neuronas de la segunda capa
n2 = 40
ep = 1

# Matrices de pesos sinápticos y vectores de polarización
W1 = ep*2*np.random.rand(n1,1)-ep
b1 = ep*2*np.random.rand(n1,1)-ep
W2 = ep*2*np.random.rand(n2,n1)-ep
b2 = ep*2*np.random.rand(n2,1)-ep
W3 = ep*2*np.random.rand(1,n2)-ep
b3 = ep*2*np.random.rand(1,1)-ep

alfa = 0.001
total_epocas = 4000
error_qua_medio = np.array(np.zeros((1,total_epocas)))

for epocas in range(total_epocas):
    sum_error = 0
    for q in range(Q):
        # Algoritmo de propagación hacia adelante
        a1 = sigmod(np.dot(W1,P[q].reshape(-1,1))+b1)
        a2 = sigmod(np.dot(W2,a1)+b2)
        a3 = np.dot(W3,a2)+b3

        # Retropropagacion hacia atras o de las sensibilidades
        e = T[q]-a3
        s3 = -2*e
        s2 = (np.diag((1-a2)*a2)*W3.T)*s3
        s1 = np.diag((1-a1)*a1)*(W2.T@s2)

        # Actualizar los pesos sinápticos y las polarizaciones
        W3 = W3-alfa*s3*a2.T
        b3 = b3-alfa*s3
        W2 = W2-alfa*s2*a1.T
        b2 = b2-alfa*s2
        W1 = W1-alfa*s1*P[q].T
        b1 = b1-alfa*s1

        sum_error = e**2+sum_error
    error_qua_medio[:,epocas] = sum_error/Q


# Verificando la solución de la red neuronal Backpropagation
p = np.arange(0,6,0.01)
a3 = np.array(np.zeros((1,np.shape(p)[0])))

for q in range(np.shape(p)[0]):
    a1 = sigmod(np.dot(W1,p[q])+b1)
    a2 = sigmod(np.dot(W2,a1)+b2)
    a3[:,q] = np.dot(W3,a2)+b3

# Gráfica
fig, ax = plt.subplots()
```

```
ax.scatter(Data[0],Data[1])
ax.plot(p,a3.reshape(-1,1),c='red')

x = np.arange(0,total_epocas,1)
fig2, ax2 = plt.subplots()
ax2.plot(x,error_qua_medio.reshape(-1,1))

plt.show()
```

Resultados

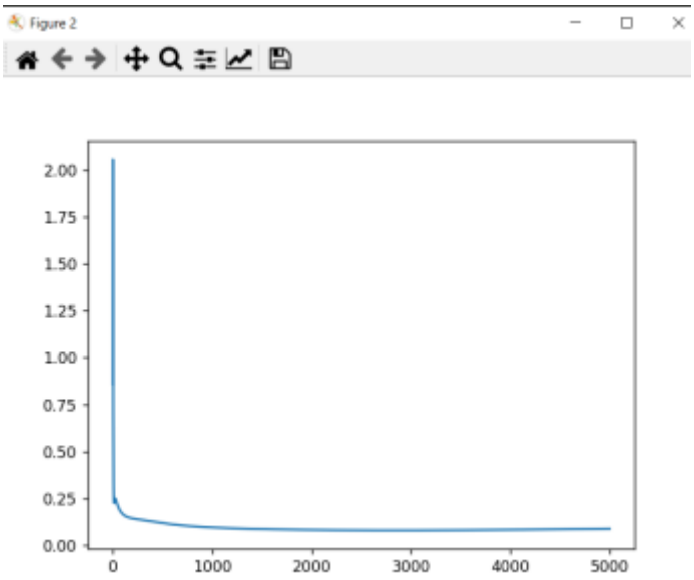

Ilustración 10.- Error cuadrático medio.

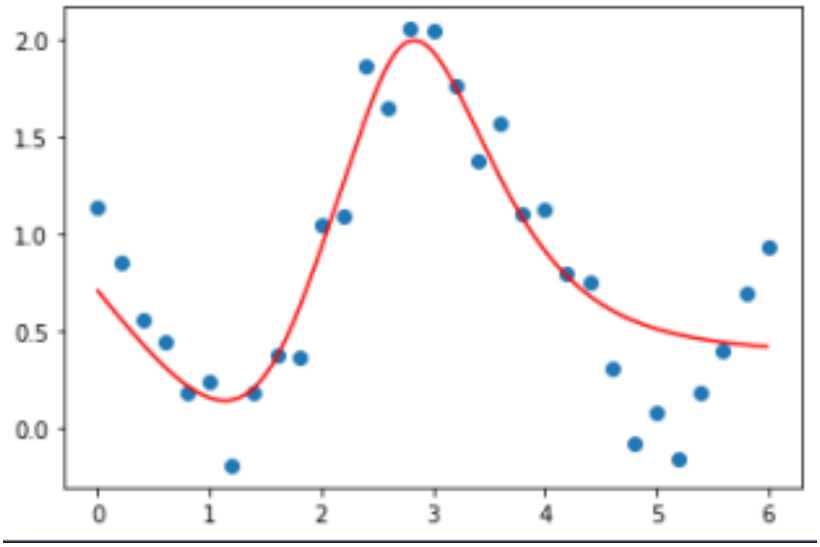

Ilustración 11.- Aproximación grafica de los datos de los diferentes precios.

Como podemos observar en la gráfica la aproximación no es del todo perfecta, ya que al principio y al final de la gráfica se puede ver una diferencia notable, el entrenamiento puede ser mejorado variando los valores de alfa, el número de épocas y el número de neuronas.

Práctica 9: Red neuronal multicapa: Clasificación de números.

Objetivo

Clasificación de números por medio de una red neuronal multicapa

Programa

```
# Universidad Autónoma Chapingo
# Departamento de Ingeniería Mecánica Agrícola
# Ingeniería Mecatrónica Agrícola
# Jym Emmanuel Cocotle Lara
# 7° 7

# Librerías
# Para vectores y matrices
import numpy as np
# Para graficación
import matplotlib.pyplot as plt

# Función tangente hiperbólica
def tanh(x):
        value = (np.exp(x)-np.exp(-x))/(np.exp(x)+np.exp(-x))
        return value

# Ruta del archivo
data_path = "Data/NumerosManuscritos.csv"
P = np.loadtxt(data_path,delimiter=",")
P = np.array(P)

Q = 500
T = np.vstack([np.ones((1,500)),-np.ones((9,500))])

for i in range(1,10):
        T = np.hstack([T,np.vstack([np.ones((i,500)),np.ones((1,500)),-
np.ones((9-i,500))])])

n1 = 25
ep = 0.1

# Matrices de pesos sinápticos y vectores de polarización
W1 = ep*(2*np.random.rand(n1,400)-1)
b1 = ep*(2*np.random.rand(n1,1)-1)
W2 = ep*(2*np.random.rand(10,n1)-1)
b2 = ep*(2*np.random.rand(10,1)-1)

alpha = 0.01

total_epocas = 100
error_cuadratico_medio = np.array(np.zeros((1,total_epocas)))

for epocas in range(total_epocas):
        sum_error = 0
        for q in range(Q):
                # Propagación hacia adelante de la entrada a la salida
                a1 = tanh(np.dot(W1,P[:,q].reshape(-1,1))+b1)
                a2 = tanh(np.dot(W2,a1)+b2)
                # Error
                e = T[:,q].reshape(-1,1) - a2
```

```
                # Propagación hacia atrás de las sensibilidades
                s2 = -2*np.diag(1-a2**2)*e
                s1 = np.diag(1-a1**2)*(W2.T@s2)

                # Actualizamos los parámetros
                W2 = W2 - alpha*s2*a1.T
                b2 = b2 - alpha*s2

                W1 = W1 - alpha*s1*P[:,q].reshape(-1,1).T
                b1 = b1 - alpha*s1

                sum_error = e.T*e
        error_cuadratico_medio[:,epocas] = sum(sum_error.reshape(-
1,1))/Q


# Visualizar el error cuadrático medio
x = np.arange(0,total_epocas,1)
fig,ax = plt.subplots()

ax.plot(x,error_cuadratico_medio.reshape(-1,1))
plt.show()

index = np.ones((1,5000))
neurona_sal = np.ones((1,5000))
for q in range(5000):
        a1 = tanh(np.dot(W1,P[:,q].reshape(-1,1))+b1)
        a = np.amax(np.dot(W2,a1)+b2)
        neurona_sal[:,q] = a
        posicion = np.where(a==neurona_sal[:,q])
        index[:,q] = posicion[0]

# Valores reales
y = np.zeros((1,500))
for j in range(1,10):
        y = np.hstack([y,j*np.ones((1,500))])

numero_aciertos = np.sum(y==index)
print(f"Total aciertos: {str(numero_aciertos)}")
porcentaje_aciertos = (numero_aciertos/5000)*100
print(f"{str(porcentaje_aciertos)} % aciertos")

for k in range(10):
        indice = np.round((4999*np.random.rand(1)+1),0)
        print(indice)
        numero_reconocido = index[:,int(indice)]
        print(f"Número reconocido: {numero_reconocido}")
        pixels = P[:,int(indice)].reshape(20,20).T
        plt.imshow(pixels,cmap="gray")
        plt.title("Número reconocido: "+str(int(numero_reconocido)))
        plt.show()
```

Resultados

Con respecto a la práctica 9, no se pudo tener un correcto entrenamiento ya que al momento de realizar la verificación los números no fueron clasificados correctamente

Conclusión

Con ayuda de la inteligencia artificial podemos entrenar diferentes redes neuronales para realizar clasificación de diferentes objetos o datos que se tengan y a partir de esta clasificación poder realizar una toma de decisiones acertada.

Bibliografía

Díez, R. P., Gómez, A. G., & de Abajo Martínez, N. (2001). Introducción a la inteligencia artificial: sistemas expertos, redes neuronales artificiales y computación evolutiva. Universidad de oviedo.